

Informe final

Integrantes: Jorge Leandro Isaac – Luis Lorenzo

Repositorio: [🔗 GitHub https://github.com/isaacjorgeleandro0-bot/PI_Mineria_Datos_1](https://github.com/isaacjorgeleandro0-bot/PI_Mineria_Datos_1)

App: [🔗 Streamlit: https://isaacjorgeleandro0-bot-pi-mineria-datos-1-apphome-hofsum.streamlit.app/](https://isaacjorgeleandro0-bot-pi-mineria-datos-1-apphome-hofsum.streamlit.app/)

1. CONTEXTO Y OBJETIVO

El proyecto desarrolla un pipeline de ciencia de datos para optimizar el análisis del comportamiento de usuarios de una plataforma de streaming. Ante la alta volatilidad del mercado, el objetivo es transformar datos brutos en activos de información confiables para identificar perfiles con riesgo de abandono (*churn*), evaluar la fricción operativa y sintetizar interacciones mediante reducción de dimensionalidad, sentando las bases para futuras estrategias de retención y modelos predictivos.

2. DATASET Y CALIDAD INICIAL

Se utilizó el archivo `streaming_users_dirty.json` (8.160 registros, 8 atributos). La auditoría inicial reveló una degradación severa: 126 registros duplicados y brechas críticas de nulos en `last_login_date` (320), `monthly_watch_time_mins` (193) y `favorite_genre` (240). Además, se detectaron *outliers* imposibles, como edades negativas, registros de 150 años y métricas de consumo o soporte técnico inferiores a cero.

3. DECISIONES DE LIMPIEZA Y PREPARACIÓN

Se ejecutó un pipeline secuencial para garantizar la robustez estadística:

- **Depuración:** Eliminación directa de 126 registros duplicados.
- **Normalización:** Estandarización de variables categóricas mediante mapeos de diccionarios para corregir errores de tipeo y formatos heterogéneos.
- **Imputación:** Los nulos en variables cualitativas se gestionaron bajo categorías controladas; en variables cuantitativas, se aplicaron medianas agrupadas por perfiles para preservar la estructura distributiva.
- **Capping:** Los valores atípicos imposibles se trataron mediante truncamiento lógico basado en rangos operativos del servicio.

El registro detallado de estas transformaciones consta en `pipeline_log.txt`.

4. HALLAZGOS DEL ANÁLISIS EXPLORATORIO (EDA)

El análisis reveló patrones accionables: si bien el Plan Básico domina la base de usuarios, presenta la mayor fricción operativa (promedio elevado de tickets de soporte). El hallazgo crítico es la desconexión comercial detectada mediante análisis multivariable: usuarios mayores de 46 años en el Plan Básico presentan niveles de consumo casi nulos ("Usuarios Fantasma"). Este segmento es altamente propenso a la baja, contrastando significativamente con el comportamiento de los adultos mayores en el Plan Premium, quienes representan el nicho con mayor *engagement*.

5. ANÁLISIS DE COMPONENTES PRINCIPALES (PCA)

Se aplicó PCA sobre edad, minutos de consumo y tickets de soporte, previa estandarización (`StandardScaler`) para evitar sesgos por escala.

Componente	Varianza	Acumulada	Atributos Dominantes
PC1	54.5%	54.5%	Actividad / Fricción (Minutos - Tickets)
PC2	31.2%	85.7%	Edad Cronológica
PC3	14.3%	100%	Variabilidad Residual

La **PC1** actúa como un indicador sintético de "Actividad y Fricción", identificando usuarios de alto consumo que demandan constante soporte técnico, representando los perfiles de mayor costo operativo.

6. CONCLUSIONES Y LIMITACIONES

El proyecto logró transformar información ruidosa en conocimiento estratégico. La identificación del perfil de riesgo permite migrar de estrategias de marketing masivo a retenciones hiper-dirigidas para adultos mayores en planes económicos.

Limitaciones: La ausencia de registros cronológicos precisos en `last_login_date` impidió un análisis de series de tiempo más profundo. Asimismo, el número reducido de variables continuas limitó el alcance del modelo PCA.

Próximos Pasos: Implementar algoritmos de *clustering* (K-Means) para segmentar automáticamente la cartera y modelos de clasificación (Random Forest) para predecir la probabilidad de baja en periodos futur